

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

**MÁSTER EN FORMACIÓN PERMANENTE EN INTELIGENCIA ARTIFICIAL
APLICADA**

TRABAJO FIN DE MÁSTER

**Quirón: un editor nativo con índice de código
verificable y una red neuronal local para el aporte de
contexto a modelos de lenguaje**

Lorenzo Juan Santacreu Pascual

Dirigido por

[COMPLETAR — Nombre del director/a]

CURSO 2025–2026

TÍTULO: Quirón: un editor nativo con índice de código verificable y una red neuronal local para el aporte de contexto a modelos de lenguaje

AUTOR: Lorenzo Juan Santacreu Pascual

TITULACIÓN: Máster en Formación Permanente en Inteligencia Artificial Aplicada

DIRECTOR/ES DEL PROYECTO: [COMPLETAR — Nombre del director/a]

FECHA: Septiembre de 2026

Índice

RESUMEN	7
ABSTRACT	8
TABLA RESUMEN	9
Capítulo 1. RESUMEN DEL PROYECTO	10
1.1 Contexto y justificación	10
1.2 Planteamiento del problema	10
1.3 Objetivos del proyecto	10
1.4 Resultados obtenidos	10
1.5 Estructura de la memoria	10
Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE	11
2.1 Estado del arte	11
2.2 Contexto y justificación	12
2.3 Planteamiento del problema	13
Capítulo 3. OBJETIVOS	14
3.1 Objetivo general	14
3.2 Objetivos específicos	14
3.3 Beneficios del proyecto	15
Capítulo 4. DESARROLLO DEL PROYECTO	16
4.1 Planificación del proyecto	16
4.2 Descripción de la solución, metodologías y herramientas empleadas	18
4.2.1 Arquitectura de memoria: un registro, dos proyecciones	19
4.2.2 Identidad del proyecto y confinamiento del editor	20
4.2.3 El índice de código: archivos, lógicas y fichas	21
4.2.4 Grafo de dependencias y recuperación	22
4.2.5 El editor nativo	23
4.2.6 Conexión con los modelos de lenguaje	25
4.2.7 La red obrera: del diseño al worker desplegado	26

4.2.8 Metodología	27
4.3 Recursos requeridos	27
4.4 Presupuesto	28
4.5 Viabilidad y despliegue	29
4.6 Resultados del proyecto	29
4.6.1 Pruebas automatizadas	29
4.6.2 Integración y recorridos completos	31
4.6.3 Diagnóstico medido de la recuperación	32
4.6.4 Evaluación exploratoria de localización	32
4.6.5 Fidelidad de las fichas	33
4.6.6 Plan de pruebas de julio y grado de ejecución	34
Capítulo 5. DISCUSIÓN	35
Capítulo 6. CONCLUSIONES	37
6.1 Conclusiones del trabajo	37
6.2 Conclusiones personales	37
Capítulo 7. FUTURAS LÍNEAS DE TRABAJO	38
Capítulo 8. REFERENCIAS	39
Capítulo 9. ANEXOS Y TRAZABILIDAD	42
Anexo A. Estudio de alternativas para la red obrera	43
Estudio: la matemática de la red obrera de Quirón	43
Cómo leer las etiquetas de evidencia	43
0. Marco del diseño inicial	44
FAMILIA 1 — Atención eficiente y gestión del KV-cache	44
1.1 Multi-head Latent Attention (MLA) — comprimir el KV · Verificado	44
1.2 Native Sparse Attention (NSA) — atención dispersa entrenable · Verificado	44
1.3 Atención lineal / lightning + SSE — estado de tamaño fijo · Verificado	45
FAMILIA 2 — Mezcla de expertos (MoE) y enrutado	46
2.1 DeepSeekMoE: experto compartido + expertos de grano fino · Verificado	46
2.2 Balanceo de carga SIN pérdida auxiliar · Verificado	46
FAMILIA 3 — Destilación profesor → estudiante	47

3.1 KD clásica (Hinton): soft targets con temperatura · Fundamental	47
3.2 Sequence-Level KD — la vía viable sin logits · Verificado	47
3.3 Reverse-KL (MiniLLM) y GKD — por qué NO nos sirven · Verificado	48
3.4 Matiz: ¿reverse-KL es realmente mejor? · Cuestión abierta	48
FAMILIA 4 — Cuantización y representación	48
4.1 AWQ — cuantizar protegiendo canales por activación · Verificado	48
4.2 GPTQ — cuantización PTQ de segundo orden · Verificado	49
4.3 InfoNCE — la pérdida que da buenos embeddings · Fundamental	49
4.4 Last-token pooling — de decoder causal a embedding · Fundamental	49
4.5 Matryoshka (MRL) — un vector, muchas dimensiones · Fundamental	49
Síntesis — la red obrera propuesta	50
Qué es reutilizable y qué es solo principio de diseño	51
Cuestiones abiertas	51
Referencias del anexo	52
Síntesis de la propuesta inicial	52

Índice de figuras

Figura 1. Cronograma del proyecto: actividades realizadas entre febrero y septiembre de 2026	18
Figura 2. Componentes de Quirón y flujo de datos entre editor, cerebro, almacenes, vectorizador y asistentes	19
Figura 3. Pantalla de vectorización al abrir un proyecto: el editor muestra el progreso del worker y queda vigilando cambios	22
Figura 4. Pantalla de bienvenida del editor	23
Figura 5. Ronda de chat con Claude sobre un proyecto sintético: el asistente lee el archivo mediante la herramienta del editor y la respuesta enlaza las fuentes con ruta y líneas	24
Figura 6. Selector de modelos de la paleta Agentes con los alias de Claude y el catálogo de la sesión de Codex	25

Índice de tablas

Tabla 1. Datos generales del trabajo	9
Tabla 2. Aspectos cubiertos por Quirón frente a los antecedentes	11
Tabla 3. Grado de cumplimiento de los objetivos específicos al cierre	15
Tabla 4. Fases del proyecto: planificación y realización	17
Tabla 5. Presupuesto del proyecto	28
Tabla 6. Pruebas automatizadas de la revisión entregada	30
Tabla 7. Evidencias funcionales registradas	31
Tabla 8. Resultados de la evaluación de localización sobre diez preguntas	33
Tabla 9. Plan de pruebas previsto en julio y grado de ejecución al cierre	34
Tabla 10. Qué es reutilizable y qué es solo principio de diseño	51

RESUMEN

Los asistentes de programación conocen el repositorio volcándolo en su ventana de contexto. Ese enfoque no escala: el coste crece con el tamaño del proyecto, la atención del modelo se diluye y en proyectos largos se pierde la consistencia: se duplican lógicas que ya existen y divergen nombres y rutas. Este trabajo presenta Quirón, un editor nativo en Rust que no pretende sustituir el contexto del modelo, sino hacerlo preciso: un índice de código local y verificable le da la localización exacta de cada lógica. Al abrir un proyecto, un worker local recorre sus archivos, extrae unidades sintácticas de Rust, redacta una ficha de cada una con un modelo pequeño (Qwen2.5-Coder-1.5B cuantizado) y la vectoriza con BGE-M3; Qdrant guarda los vectores y Neo4j la pertenencia y las llamadas aproximadas. Cada ficha lleva proyecto, ruta, símbolo, líneas y hash, y la recuperación comprueba su vigencia contra el archivo antes de entregarla al asistente elegido (Claude, Codex, un servidor compatible u Ollama). Un registro inmutable de eventos encadenado por hash conserva la memoria del sistema. La red propia prevista inicialmente se sustituyó por modelos preentrenados y queda como estudio de alternativas. Las evidencias cubren indexación incremental, aislamiento entre proyectos, rondas con proveedores reales y una evaluación exploratoria de localización: el objetivo apareció entre los cinco primeros resultados en las diez preguntas, con fichas que suponen el 0,6 % del código de referencia. El ahorro en tareas completas y la prevención de duplicados siguen como hipótesis por medir.

Palabras clave: modelos de lenguaje, recuperación aumentada, índice de código, inferencia local, editor nativo, trazabilidad.

ABSTRACT

Programming assistants learn about a repository by dumping it, in whole or in part, into their context window. This approach does not scale: cost grows with project size, the model's attention gets diluted and, in long projects, consistency erodes: existing logic gets duplicated and names and paths diverge. This work presents Quirón, a native Rust editor that does not try to replace the model's context but to make it precise: a local, verifiable code index gives the model the exact location of every piece of logic. When a project is opened, a local worker walks its files, extracts Rust syntax units, writes a record for each one with a small model (quantized Qwen2.5-Coder-1.5B) and embeds it with BGE-M3; Qdrant stores the vectors and Neo4j the membership and approximate call relationships. Each record carries project, path, symbol, lines and hash, and retrieval checks its freshness against the file before handing it to the assistant, which can be Claude, Codex, an OpenAI-compatible server or Ollama. An immutable, hash-chained event log keeps the system's memory. Training a proprietary network, part of the initial plan, was replaced by pre-trained models and is documented as a study of alternatives. The evidence covers incremental indexing, isolation between projects, complete rounds with real providers and an exploratory retrieval evaluation: the target appeared among the top five results in all ten questions, with records amounting to 0.6 % of the reference source. Savings on complete tasks and duplicate prevention remain hypotheses to be measured.

Keywords: language models, retrieval augmentation, code indexing, local inference, native editor, traceability.

TABLA RESUMEN

Tabla 1. Datos generales del trabajo

Campo	Datos
Nombre y apellidos	Lorenzo Juan Santacreu Pascual
Título del proyecto	Quirón: un editor nativo con índice de código verificable y una red neuronal local para el aporte de contexto a modelos de lenguaje
Directores del proyecto	[COMPLETAR]
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa	NO
El proyecto ha implementado un producto	Sí: editor nativo con índice de código local y conexión a asistentes
El proyecto ha consistido en el desarrollo de una investigación o innovación	Sí: estudio de la matemática de los modelos recientes para una red local pequeña (Anexo A)
Objetivo general del proyecto	Construir un editor nativo cuyo contexto para el modelo de lenguaje procede de un índice verificable, vectores y grafo por proyecto, mantenido de forma continua por una red neuronal local pequeña

Capítulo 1. RESUMEN DEL PROYECTO

1.1 Contexto y justificación

Trabajar con repositorios grandes exige saber qué hace cada archivo, de qué depende y qué cambió. Los asistentes actuales obtienen ese conocimiento volcando código en la ventana de contexto, y el volcado tiene dos costes que crecen con el proyecto: el económico, que facturado por token de API resulta insostenible a gran escala, y el de consistencia: a cada relectura parcial el asistente renombra lo que ya tenía nombre, duplica lógicas y recrea carpetas. A la vez, los aceleradores locales hacen viable un reparto nuevo: un modelo pequeño en el propio equipo realiza el trabajo continuo y barato de indexar y resumir, y el modelo grande se reserva para lo que solo él puede hacer. La pieza local no genera código: mantiene el índice.

1.2 Planteamiento del problema

La pregunta motriz es: **¿puede un índice consultable, vectores, grafo y un modelo local pequeño que lo mantiene, dar al modelo de lenguaje la localización exacta de cada lógica de un repositorio, de modo que gane agilidad, ahorre contexto y deje de perder consistencia, con toda afirmación verificable contra el código de origen?** El índice no sustituye al contexto del modelo: lo hace preciso. El proyecto combina desarrollo de producto e investigación aplicada (el estudio de la red obrera), sin colaboración empresarial.

1.3 Objetivos del proyecto

Diseñar y construir un editor nativo cuyo contexto proviene de un índice verificable mantenido por una red neuronal local; el Capítulo 3 detalla los objetivos específicos y su grado de cumplimiento.

1.4 Resultados obtenidos

Abrir una carpeta produce en segundo plano un índice de fichas vectorizadas por proyecto que el chat consulta y devuelve como fuentes clicables. Las pruebas registradas cubren apertura, consultas, cambios, borrados, exclusión de secretos y aislamiento entre proyectos, además de rondas completas desde la interfaz con Claude y Codex. En una evaluación exploratoria de localización con diez preguntas, el objetivo apareció entre los cinco primeros resultados en todos los casos. La red propia no se entrenó: el worker usa modelos preentrenados, y su diseño queda como estudio.

1.5 Estructura de la memoria

Los capítulos 2 a 9 presentan, por este orden, los antecedentes, los objetivos, el desarrollo y la evaluación, la discusión y los límites, las conclusiones, el trabajo futuro, las referencias y los anexos con las evidencias.

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

2.1 Estado del arte

El problema general es el del contexto como recurso escaso: un modelo de lenguaje solo razona sobre lo que cabe en su ventana, y llenarla tiene coste económico y cognitivo.

El contexto en los asistentes de programación. La práctica dominante combina el volcado (archivos completos o repositorios resumidos) con la recuperación aumentada: fragmentos seleccionados por similitud vectorial se anteponen a la consulta. La recuperación clásica sobre código presenta dos carencias conocidas: la similitud responde a «qué se parece a esto», pero no a «de qué depende esto», y los fragmentos recuperados no suelen ser verificables contra su origen, lo que deja pasar afirmaciones sin evidencia. Existen trabajos que recuperan información del repositorio para asistir a modelos de código: RepoCoder combina recuperación por similitud y generación iterativa [25]; GraphCoder utiliza grafos de contexto de código para recuperar fragmentos [26]; RepoGraph ofrece una estructura de repositorio que sirve de apoyo a agentes de ingeniería de software [27]. Estos antecedentes sitúan a Quirón: la recuperación de código mediante grafos y vectores no es una invención de este trabajo. Lo que se estudia aquí es la integración de un worker local con un editor nativo, proyecciones incrementales y comprobación de vigencia de las fichas. La matriz siguiente describe ese alcance, no una clasificación exhaustiva de productos.

Tabla 2. Aspectos cubiertos por Quirón frente a los antecedentes

Aspecto	Aportación desarrollada en Quirón
Localización	Consulta de fichas con ruta, símbolo, líneas y hash, dentro del editor
Mantenimiento	Monitor incremental por proyecto y retirada de unidades desaparecidas
Modelos	Generador local sustituible y embeddings independientes
Interfaz	Editor nativo con estado del worker, proveedores y fuentes recuperadas
Dependencias	Pertenencia y aproximación de llamadas Rust; cobertura incompleta
Evaluación	Integración y casos exploratorios; falta comparación de tareas completas

Representación vectorial del código. Los embeddings modernos se entrenan con pérdidas contrastivas tipo InfoNCE [13], que acercan pares positivos y separan negativos. Sobre backbones autoregresivos, el estado del último token sirve como vector de la secuencia (*last-token pooling*) [14][15], lo que permite que un mismo modelo genere texto y produzca embeddings alineados. El aprendizaje de representaciones anidadas (Matryoshka) [16] ordena la información por importancia en las primeras dimensiones, de modo que un vector de 1024 dimensiones puede truncarse con pérdida acotada si se entrenó para ello. En esta versión se emplea bge-m3 [19][29] (1024 dimensiones) tal como se distribuye: no se entrena una representación propia ni se demuestra que sus vectores puedan truncarse conservando calidad.

Almacenes especializados. Las bases vectoriales (Qdrant [17]) resuelven similitud aproximada a escala con filtros exactos sobre la carga útil; las bases de grafo (Neo4j [18]) resuelven recorridos de dependencia. Ninguna de las dos responde por sí sola a las dos preguntas del índice de código; la contribución está en unir las con una identidad estable por unidad. La existencia de un grafo no implica que sus relaciones resuelvan todos los tipos, importaciones o llamadas del programa.

La matemática de los modelos recientes, como caja de piezas. El estudio realizado para este trabajo (Anexo A) extrae los mecanismos matemáticos de los modelos de lenguaje recientes y evalúa su reutilización en una red pequeña, local y exportable:

- *Atención eficiente.* La atención latente multi-cabeza (MLA) comprime el KV-cache a un latente de rango bajo [1][2]; la atención dispersa nativa (NSA) combina compresión, selección top-n y ventana local con un gate diferenciable [3]; la atención lineal reordena el producto para mantener un estado de tamaño fijo $d \times d$ con coste constante por paso [4][5][6], mitigando su pérdida de recuperación asociativa con actualizaciones dispersas de estado (SSE) [7]. Esa propiedad no se extiende al modelo completo si se añaden capas de atención completa sobre todo el historial.
- *Mezcla de expertos.* El experto compartido más expertos de grano fino desacopla capacidad de cómputo por token [8], y el balanceo de carga sin pérdida auxiliar corrige el enrutado sin contaminar el objetivo de entrenamiento [9].
- *Destilación.* En la destilación profesor–estudiante, la variante clásica con temperatura requiere los logits del profesor [10]; la destilación a nivel de secuencia solo requiere su texto [11]. Las variantes on-policy (MiniLLM, GKD) exigen de nuevo logits [12a][12b], y la superioridad del KL inverso es cuestión abierta en distribuciones discretas [12c]. QLoRA [24] muestra además que es posible ajustar modelos preentrenados con memoria reducida.
- *Cuantización.* AWQ protege por reescalado los canales salientes identificados por la magnitud de la activación [20]; GPTQ redistribuye el error de redondeo con información de segundo orden [21]. Ambas son post-entrenamiento.

Hardware y modelos abiertos. La generalización de aceleradores de consumo, de equipos con memoria unificada y de runtimes portables (llama.cpp [28], ONNX Runtime [22]) hace práctico ejecutar de forma continua modelos pequeños en local. Los informes de Qwen2.5-Coder [23] y Qwen3 [30] describen modelos abiertos de código con tamaños desde 0,5 B hasta decenas de miles de millones de parámetros, cuantizables a 4 bits.

2.2 Contexto y justificación

La motivación es triple.

Económica. El volcado de contexto se paga por token. Con suscripción, el coste lo absorbe el proveedor hasta el límite del plan; por API, el coste es proporcional al tamaño del proyecto

y a la frecuencia de consulta. Un índice que entrega solo los fragmentos necesarios ataca la raíz del gasto: el proyecto entero deja de viajar en cada turno. El acceso principal a los modelos se realiza por las sesiones de suscripción existentes, mediante las CLI oficiales de Claude y Codex; las conexiones compatibles con OpenAI admiten una clave de API si el usuario dispone de ella. La contrapartida de la vía por suscripción, la pérdida de control sobre los parámetros de muestreo del modelo, se asume explícitamente.

De fiabilidad y consistencia. Un modelo sin mapa del repositorio comete errores por omisión: reimplementa lógica existente, ignora dependencias, afirma sin evidencia. En proyectos largos comete además errores de consistencia, los más costosos de deshacer: cada vez que relee una parte del proyecto, bautiza con otro nombre lo que ya tenía uno, duplica una lógica o crea una carpeta nueva para algo que ya existía. Un índice con identidad estable por unidad ataca exactamente eso: el modelo va directamente a la lógica localizada en lugar de redescubrirla. Cada fragmento que Quirón entrega lleva ruta, símbolo, rango y hash; toda afirmación es contrastable con el código de origen. La verificabilidad no es una capa estética: es la diferencia entre una respuesta y una conjetura.

De soberanía. El código no abandona la máquina salvo en los fragmentos que el usuario decide enviar al modelo: las fichas recuperadas y las lecturas que el asistente pide mediante las herramientas del editor. Los secretos (.env, claves, material criptográfico) se niegan siempre, incluso dentro del proyecto. La API local del sistema adopta el formato de mensajes de Anthropic y sirve indistintamente a Claude, Codex o un servidor compatible: el índice no depende del proveedor, por diseño.

El resultado se concibe para el uso individual de un desarrollador en su equipo, sobre repositorios propios de tamaño medio; el índice se construye y se consulta en local.

2.3 Planteamiento del problema

Del análisis anterior se desprende la carencia: no existe una solución que una (a) recuperación híbrida vectorial y de grafo con identidad estable y verificable por unidad de código, (b) mantenimiento continuo e incremental del índice por un modelo local pequeño que **propone y no ejecuta**, (c) independencia de un proveedor concreto, con acceso por suscripción o por API según elija el usuario, y (d) la conservación de la consistencia del repositorio como responsabilidad activa del sistema, no como efecto que se espera del modelo. Los asistentes comerciales vuelcan contexto y no exponen su índice; las soluciones de recuperación sobre código no integran el grafo de dependencias ni anclan sus fragmentos a hashes; los modelos pequeños locales no se han aplicado como mantenedores de un índice bajo validación determinista. Ese hueco define los objetivos del capítulo siguiente.

Capítulo 3. OBJETIVOS

3.1 Objetivo general

El objetivo general del presente trabajo, tal como se formuló en el anteproyecto, consiste en **diseñar y construir un entorno de desarrollo nativo cuyo contexto para el modelo de lenguaje procede de un índice verificable, un índice vectorial y un grafo de dependencias por proyecto, mantenido de forma continua por una red neuronal propia, local y pequeña.**

Durante el desarrollo se priorizó el recorrido funcional completo con modelos preentrenados frente al entrenamiento de la red propia. La red neuronal local que mantiene el índice en la versión entregada es, por tanto, un modelo pequeño preentrenado y sustituible, no una red entrenada por el autor. Se conserva la numeración de los objetivos para hacer visible esa evolución en lugar de presentar una reformulación como cumplimiento retroactivo del planteamiento inicial.

3.2 Objetivos específicos

- **OE1.** Diseñar la arquitectura de memoria del sistema: registro inmutable encadenado por hash como única fuente de verdad, y proyecciones desechables (índice vectorial y grafo) reconstruibles.
- **OE2.** Implementar el editor nativo con confinamiento al proyecto: guardia de rutas con veredictos diferenciados (secreto, exterior, ruido), fallo cerrado sin proyecto abierto.
- **OE3.** Construir el indexador determinista e incremental sobre tres tipos de unidad (Archivo, Lógica, Cambio), con identificador estable, hash y proyecto en cada unidad.
- **OE4.** Construir el grafo de dependencias particionado por proyecto, con relaciones extraídas por análisis estático y nunca por inferencia del modelo.
- **OE5.** Implementar el worker de recuperación: filtro exacto por proyecto dentro del almacén, búsqueda vectorial, expansión por el grafo, reordenación con reranker y recorte al presupuesto de contexto.
- **OE6.** Estudiar la matemática de los modelos de lenguaje recientes y seleccionar, con criterio de evidencia, los mecanismos reutilizables en una red pequeña exportable a ONNX/Rust.
- **OE7.** Entrenar la red obrera por destilación a nivel de secuencia desde un modelo profesor accesible solo por texto, y desplegarla cuantizada en el runtime local.
- **OE8.** Medir el sistema: reducción del consumo de contexto frente al volcado, calidad de recuperación, aislamiento entre proyectos y fidelidad de las fichas generadas.

Tabla 3. Grado de cumplimiento de los objetivos específicos al cierre

Objetivo	Estado al cierre
OE1	Cumplido en el registro: cadena v2 con hash de todos los campos, transacciones y anclaje compatible; reconstrucción completa del índice de código desde el registro pendiente, el índice se reconstruye desde los archivos
OE2	Cumplido: editor y guardia de rutas con pruebas; quedan carreras posibles del sistema de archivos
OE3	Cumplido para Archivo y Lógica en Rust; el tipo Cambio está definido sin historial completo integrado
OE4	Parcial: pertenencia y llamadas aproximadas en Rust; tipos, importaciones y dependencias completas pendientes
OE5	Parcial: filtro dentro de Qdrant, búsqueda vectorial y expansión limitada por llamadas; reranker y presupuesto de contexto pendientes
OE6	Cumplido: estudio de alternativas con etiquetas de evidencia (Anexo A); no se construyó un nuevo backbone
OE7	No cumplido: entrenamiento excluido del alcance; sustituido por la integración, descarga y selección de modelos preentrenados
OE8	Parcial: evidencias funcionales, aislamiento y evaluación exploratoria de localización; el ahorro en tareas completas no está medido

3.3 Beneficios del proyecto

El beneficio directo es económico y de agilidad: con las lógicas localizadas, el modelo va directo a donde debe ir, y el ahorro de contexto crece precisamente donde más duele, en los repositorios grandes y los proyectos largos. El beneficio de calidad es la conservación de la consistencia: el modelo no repite una lógica que ya existe porque el índice se la pone delante, con evidencia. El beneficio de soberanía es que el código permanece en la máquina y el sistema no depende de un proveedor único. Por último, la reconstruibilidad de las proyecciones convierte el peor error posible del worker en un incidente reversible: una ficha que se regenera o un grafo que se reprojeta, nunca una memoria falsificada. Un hash coincidente acredita la vigencia del archivo, no la corrección de su resumen; Quirón no dispone todavía de un detector automático de lógica duplicada ni de resúmenes por carpeta, que quedan como líneas futuras.

Capítulo 4. DESARROLLO DEL PROYECTO

4.1 Planificación del proyecto

El sistema se levanta en fases, y cada una exige que la anterior funcione. La decisión rectora es que **la red neuronal es la última pieza, no la primera**: las cinco primeras fases producen un sistema útil sin una sola red entrenada por el autor; la sexta lo mejora, no lo sostiene. Construir la red antes que el indexador significaría entrenarla sobre un corpus que no existe. Esa decisión fue la que permitió cerrar el proyecto cuando la sexta fase cambió de naturaleza.

Tabla 4. Fases del proyecto: planificación y realización

Fase	Periodo (2026)	Contenido planificado	Realización
F0	Febrero	Anteproyecto y definición del alcance	Realizada
F1	Febrero–abril	Infraestructura de servicios: cerebro con API local, embeddings y reranker, pasarela a modelos, Qdrant y Neo4j en contenedores	Realizada; el servicio de embeddings pasó después a ejecutarse dentro del cerebro
F2	Abril–junio	Editor nativo, integración de escritorio, confinamiento con pruebas	Realizada
F3	Junio–julio	Arquitectura de memoria: registro inmutable, estados de promoción, diagnóstico medido de la recuperación	Realizada
F4	Julio	Estudio matemático de la red obrera sobre más de 40 fuentes primarias	Realizada (Anexo A)
F5	Agosto–septiembre	Índice de código, grafo de dependencias y recuperación conectada al chat	Realizada con el alcance del Capítulo 3: unidades de Archivo y Lógica en Rust, aristas de llamadas aproximadas, recuperación sin reranker
F6	Septiembre	Red obrera: corpus, destilación, cuantización y despliegue; medición final	Sustituida: worker con modelos preentrenados descargables, selección por dispositivo, proveedores desde la interfaz, paquete Linux y evaluación exploratoria
Cierre	10–13 de septiembre	Redacción final	Contraste entre código y memoria, registro v2, fichas v5, limpieza del código y memoria




Figura 1. Cronograma del proyecto: actividades realizadas entre febrero y septiembre de 2026

El esfuerzo en horas se recoge en el presupuesto del apartado 4.4. El historial Git del repositorio de entrega comienza el 29 de agosto de 2026 con la reorganización documental del proyecto; el código de las fases F1 a F4 se incorporó en ese primer commit. La entrega del programa, acordada con el tutor, se realiza mediante repositorio: **[COMPLETAR — URL del repositorio de entrega]**. La revisión entregada lleva la etiqueta entrega-tfm; el paquete binario incluye un inventario de hashes (BUILD.json y SHA256SUMS).

4.2 Descripción de la solución, metodologías y herramientas empleadas

Quirón se compone de cuatro piezas: el editor nativo, el cerebro (quiron-brain: índice, registro de eventos y API local), la pasarela hacia los asistentes (vertex-gateway) y el vectorizador local (llama.cpp con un modelo Qwen). En esta memoria «worker» designa el proceso del cerebro que mantiene el índice; en la interfaz aparece como «vectorizador», y el modelo Qwen que redacta las fichas es su generador. La figura resume los componentes y los flujos de datos entre ellos.




Figura 2. Componentes de Quirón y flujo de datos entre editor, cerebro, almacenes, vectorizador y asistentes

4.2.1 Arquitectura de memoria: un registro, dos proyecciones

La decisión central del diseño es una asimetría. El **registro de eventos** es inmutable: cada evento (decisión, acción, observación, ejecución, artefacto, alerta, invariante o consulta, con agente, proyecto, descripción, entradas, salidas y métricas) se encadena con el hash del anterior mediante Blake3, de modo que alterar uno invalida todos los posteriores; una afirmación equivocada no se borra, se corrige emitiendo otra que la reemplaza (supersedes) o la retracta (retracted_by). Sobre el registro se construye la memoria del agente: envolturas con estados de promoción, revisión y retractación, y proyecciones semánticas en Qdrant consultables por similitud (/search, /crag, /recall). Las **proyecciones**, el índice vectorial en Qdrant y el grafo en Neo4j, son desechables por definición: si se corrompen, se destruyen y se reconstruyen. Esa propiedad es la que permite que un modelo escriba en ellas sin poner en riesgo nada irreversible. El editor anota en el registro las ediciones de código como eventos; los hilos del chat se guardan por proyecto en la carpeta .quiron/.

El cerebro utiliza Sled [32] como almacenamiento local; el nombre histórico del módulo storage/rocks.rs no significa que se utilice RocksDB. La revisión final del registro encontró que la versión inicial del hash no cubría todos los campos del evento y que los índices se escribían en operaciones separadas. La corrección, denominada v2, calcula el hash sobre la serialización completa del evento (salvo su propio hash), con separación de dominio y longitudes delimitadas; evento, índices, versión, anclaje y cabecera se escriben en una transacción de Sled que solicita persistencia antes de confirmar; los escritores comparten un bloqueo y los identificadores duplicados se rechazan, también dentro de un

lote. Los eventos históricos conservan sus bytes y su algoritmo, y el primer evento v2 incorpora un anclaje del contenido completo observado al migrar, lo que permite detectar cambios posteriores.

Hay una diferencia con el diseño de julio que conviene dejar clara: el índice de código no se reconstruye desde el registro, sino desde los propios archivos. El worker mantiene un manifiesto y una caché de fichas y vectores en Sled, y confirma cada archivo después de recibir el acuse de Qdrant y de Neo4j. Para el código, la fuente de verdad es el archivo y su hash; el registro conserva la historia de decisiones y ediciones, no la de cada unidad de código. Registrar cambios suficientes para reconstruir el índice desde el registro es una línea futura.

4.2.2 Identidad del proyecto y confinamiento del editor

Cada proyecto recibe un identificador propio, un ULID en `.quiron/project.id`, estable frente a mover o renombrar la carpeta; la aplicación migra el estado histórico de `.llore`. El identificador, no la ruta ni el nombre, aparece en el registro, en la carga útil de cada punto vectorial y en el nodo raíz del grafo. La identidad heredada de eventos antiguos se resuelve anotando, nunca reescribiendo: reescribir el pasado rompería la cadena. El worker exige una raíz válida y una identidad coincidente; una copia de la carpeta con la misma identidad no puede monitorizarse simultáneamente como otro proyecto.

El editor arranca sin proyecto y falla cerrado: sin raíz no se lee nada y el chat queda deshabilitado. La primera vez que se abre una carpeta, Quirón pide permiso y explica qué va a hacer con ella antes de crear la identidad. Toda ruta se clasifica antes de tocar el disco comparando formas canónicas, de modo que ni `.` ni un enlace simbólico permiten salir, con tres veredictos: `Secret` (negación absoluta, incluso dentro del proyecto: `.env`, `*.pem`, `id_rsa`, `.ssh/`, `.codex/`), `Outside` (fuera de la raíz; requiere abrir ese proyecto o autorizar) y `Noise` (artefactos generados: ocultos, legibles bajo petición). Un `.env` es secreto; un `.env.example` es una plantilla y se lee. Lo que la guardia niega al editor se lo niega también al worker y a las herramientas del asistente: si un archivo no puede abrirse en una pestaña, tampoco puede acabar convertido en un vector ni leído por el modelo. El confinamiento no es una capa de la interfaz; es la frontera del sistema. La guardia tiene 10 pruebas propias y otras 9 cubren las herramientas del chat que la atraviesan. Las reglas se basan en rutas y nombres; no garantizan detectar credenciales incrustadas dentro de un archivo de código, y persisten carreras posibles entre inspeccionar una ruta y abrirla.

4.2.3 El índice de código: archivos, lógicas y fichas

El índice se define sobre tres tipos de unidad: **Archivo** (ruta, lenguaje, hash y una descripción de su responsabilidad), **Lógica** (una por función, método, estructura, enumeración o trait: símbolo, firma, rango de líneas, propósito y hash) y **Cambio** (hash anterior y posterior con motivo). En la versión entregada, el worker genera unidades de Archivo para las extensiones admitidas y unidades de Lógica para Rust mediante Tree-sitter [31], cuya firma y líneas proceden del analizador y no del modelo; el tipo Cambio está definido pero no se registra un historial completo. La cobertura no incluye toda construcción del lenguaje, y los demás lenguajes tienen por ahora ficha de archivo.

Al abrir un proyecto, el worker recorre la carpeta excluyendo enlaces simbólicos, nombres sensibles y directorios generados; cuando la raíz es un repositorio Git respeta el conjunto de archivos seguidos o no ignorados. Los límites son 512 KiB por archivo y 10 000 archivos o 64 MiB de texto por barrido, y una carpeta que los supera se rechaza con la indicación de abrir un proyecto concreto. Después se queda vigilando: revisa cambios cada diez segundos, rehace solo lo que cambia, retira las unidades desaparecidas y comprueba periódicamente la presencia de las unidades en los almacenes para reparar pérdidas desde la caché. Hasta ocho proyectos pueden permanecer monitorizados.

Para cada unidad, el generador recibe hasta 6 000 caracteres numerados por línea y las definiciones de constantes Rust referenciadas cuando caben en un contexto acotado; esas definiciones participan en la huella de caché, de modo que un cambio en ellas invalida la ficha, y las entradas recortadas se marcan como parciales. La respuesta solicitada (ficha v5) es un propósito en una frase completa, el contexto que el modelo no ha podido resolver y entre una y tres líneas de evidencia; el programa copia los fragmentos citados desde el código y convierte sus líneas a posiciones del archivo, de modo que el modelo no redacta las citas. Se rechazan frases incompletas, referencias inexistentes, cifras ausentes del contexto, menciones de lenguajes sin respaldo en la entrada, salidas inválidas y repeticiones de instrucciones. En esos casos se guarda una ficha estructural del analizador con el motivo y `summary_origin=parser`; las aceptadas llevan `model`. Los errores de conexión con el servidor del modelo son reintentables. Las reglas y las citas verifican restricciones concretas, no toda afirmación semántica de la descripción: el modelo puede omitir ramas o efectos.

BGE-M3 [19][29], ejecutado en proceso sobre ONNX Runtime [22], vectoriza ruta, símbolo, firma y descripción. El código completo no se copia al texto vectorizado: el punto conserva ruta, rango y hash Blake3 del archivo para recuperar el original cuando haga falta. Si el archivo cambia, la ficha deja de valer hasta que se rehace: la búsqueda comprueba el archivo antes de devolverla.

El aislamiento entre proyectos se apoya en tres puntos obligatorios: toda unidad lleva `project` en su carga útil; Qdrant aplica el filtro exacto de proyecto y de versiones de modelos dentro de la consulta, antes de calcular similitud; y en Neo4j todo nodo cuelga de un nodo raíz `CodeProject` que ninguna consulta atraviesa. Un fragmento de un proyecto no

puede aparecer en las respuestas de otro; la propiedad se probó con dos identidades distintas y contenido idéntico.




Figura 3. Pantalla de vectorización al abrir un proyecto: el editor muestra el progreso del worker y queda vigilando cambios

4.2.4 Grafo de dependencias y recuperación

La similitud vectorial no puede responder «de qué depende esto» ni «qué se rompe si lo cambio»; esas preguntas exigen un grafo. El diseño prevé nodos de proyecto, archivo, módulo, símbolo y cambio con relaciones de importación, llamada, dependencia, definición y cambio, extraídas del árbol sintáctico. En la versión entregada Neo4j contiene los nodos `CodeProject` y `CodeUnit` y las relaciones `HAS_UNIT`, `DEFINED_IN` y `CALLS`. Las llamadas se extraen sintácticamente y se enlazan por reglas de nombre y archivo: `Tipo::metodo` y las funciones por símbolo exacto en todo el proyecto, y los métodos por nombre suelto solo dentro del mismo archivo, porque `push`, `get` o `new` chocan con la biblioteca estándar. Si el análisis estático no resuelve una llamada de forma única, la relación no se crea: lo ambiguo no se inventa. Una coincidencia única de nombre no prueba la resolución semántica del destino, ya que se pierden prefijos de módulo y no se resuelve el tipo del receptor; no se ofrecen garantías de análisis de impacto completo. Un nodo del grafo y un punto vectorial se corresponden por el identificador estable de la unidad.

El worker de recuperación diseñado une los dos almacenes en cinco pasos: filtro exacto por proyecto, búsqueda vectorial (candidatos, no respuestas), expansión acotada por el grafo, reordenación con un reranker y recorte al presupuesto de contexto del consumidor. La versión entregada implementa los tres primeros: la búsqueda de código filtra proyecto y modelos dentro de Qdrant, revalida ruta y hash antes de devolver cada acierto y añade hasta un vecino por llamadas cuando puede obtenerlo del grafo, filtrando proyecto y versiones de modelos también en el vecino y conservando su ficha y su indicador de entrada parcial. No

se ejecuta un reranker ni se aplica un presupuesto global medido con el tokenizador del asistente. El checkpoint del indexador solo avanza tras confirmar la escritura en ambos almacenes: una unidad presente en Qdrant y ausente del grafo es un fallo visible y reintentable. La memoria de eventos utiliza otro recorrido, en el que parte del filtrado por proyecto ocurre después de buscar; las garantías del índice de código no se extienden automáticamente a esos endpoints.

4.2.5 El editor nativo

El editor de Quirón es una aplicación nativa en Rust: `winit` para la ventana, `tiny-skia` y `softbuffer` para el rasterizado, `taffy` para el layout y `cosmic-text` para el texto. En el repositorio, el crate conserva el nombre `llore_editor`, heredado de un prototipo anterior; el producto es Quirón. No hay navegador ni webview; las tipografías (Inter, JetBrains Mono y los iconos Lucide, con licencia libre) viajan dentro del binario. Un fotograma de interfaz costó 2,4 ms en la medición de julio (1,0 ms de modelado de texto y 1,4 ms de composición de glifos); con repintado por eventos no hay motivo para mover el dibujado a la GPU. El conjunto del editor suma unas 38 000 líneas de Rust repartidas en siete crates, 27 000 de ellas en el de interfaz. La aplicación está integrada en el escritorio con entrada de menú, icono y `app_id` coherente en Wayland y X11.




Figura 4. Pantalla de bienvenida del editor

La interfaz se organiza en una barra lateral con los hilos de conversación del proyecto, los repositorios recientes, la búsqueda de archivos y el explorador; una zona central con el chat y las pestañas de edición; y un panel «Segundo plano» que muestra lo que hace la aplicación en cada momento: la fase del índice, los archivos leídos, el archivo que se analiza, las fichas escritas por el modelo o por el analizador y las herramientas ejecutadas en el turno. La barra del chat crece hasta seis líneas, admite adjuntar y mencionar archivos del

proyecto, recuperar preguntas anteriores, cambiar de modelo y elegir la longitud de la respuesta; bajo cada respuesta, las fichas recuperadas aparecen como `archivo:líneas` · símbolo y al pulsarlas se abre el archivo en esa línea. El explorador ofrece las operaciones habituales de archivos y carpetas dentro del proyecto. El manual de uso se abre desde la propia aplicación con F1.

Las herramientas ofrecidas al asistente son `read_file`, `list_files` y `search_text`. Se ejecutan mediante la guardia del proyecto y con límites de salida: 24 000 caracteres por lectura y 60 aciertos de 200 caracteres en las búsquedas. Son manos de lectura, no de edición: el asistente localiza con las fichas y comprueba leyendo, y los cambios los hace el usuario en el editor.




Figura 5. Ronda de chat con Claude sobre un proyecto sintético: el asistente lee el archivo mediante la herramienta del editor y la respuesta enlaza las fuentes con ruta y líneas

4.2.6 Conexión con los modelos de lenguaje

La API local del cerebro (127.0.0.1:8766, autenticación por bearer token) es la única puerta al índice: ningún cliente habla directamente con Qdrant ni con Neo4j. El editor envía cada turno a /v1/messages, que adopta el formato de mensajes de Anthropic; el cerebro recupera las fichas del proyecto abierto, las añade como pistas al contexto y entrega la petición a la pasarela vertex-gateway, que concentra la salida hacia proveedores en un único punto de egreso con cuatro adaptadores: `claude_cli` y `codex_cli`, que invocan las CLI oficiales ya autenticadas con la sesión de suscripción; `openai_compatible`, para OpenAI, un servidor compatible en la red local o la interfaz compatible de Ollama; y `ollama_native`. Cada conversación transmite su proveedor y modelo sin cambiar la configuración del servicio, de modo que elegir Claude o Codex no detiene el worker; en Codex se transmite también el esfuerzo de razonamiento. El selector reúne los alias de Claude (Sonnet, Opus y Haiku) y el catálogo de modelos visibles en la sesión de Codex, que puede actualizarse desde la interfaz. Una suscripción no proporciona un identificador universal de acceso: cada adaptador tiene su propio mecanismo y límites, y los resultados históricos no garantizan disponibilidad futura.




Figura 6. Selector de modelos de la paleta Agentes con los alias de Claude y el catálogo de la sesión de Codex

El bucle de herramientas es del editor, no del proveedor: cuando el modelo pide leer o buscar, la pasarela devuelve la solicitud, el editor la ejecuta con la guardia y aporta el resultado al siguiente turno. Codex CLI se ejecuta en un directorio temporal, sin la configuración personal del usuario, con sus herramientas nativas de archivos, comandos y servicios desactivadas y con las credenciales del cerebro, de los almacenes y de otros proveedores retiradas del entorno del subprocesso. Es una conversación propia de Quirón, sin heredar el hilo del IDE.

4.2.7 La red obrera: del diseño al worker desplegado

La red obrera se concibió como una red neuronal pequeña y propia, entrenada sobre las unidades del índice, que trabaja de forma continua. Sus tareas, por orden: mantener el project de cada unidad, clasificar unidades por tipo y responsabilidad, redactar la ficha de cada archivo y cada lógica dentro de los límites, y priorizar candidatos a lógica duplicada para revisión humana. Sus límites no se negocian: toda salida cumple un esquema, se refiere al hash vigente de la unidad y supera validaciones deterministas antes de escribirse; una salida que no valida se descarta y queda registrada. La red no escribe en el registro ni controla el sistema de archivos ni los almacenes: **propone; no ejecuta**.

Del estudio del estado del arte (Anexo A) se deriva su diseño: (1) un backbone híbrido mayormente lineal, con estado recurrente $d \times d$ y capas esporádicas de atención completa (~7:1) [4][7]; (2) una cabeza compartida más cabezas por tipo de lógica, inspiración del experto compartido sin enrutado disperso [8]; (3) embeddings de código de 1024 dimensiones entrenados con InfoNCE, obtenidos por last-token pooling y truncables por Matryoshka [13][14][16], de modo que el vector de una unidad sea el estado del último token del resumen que la propia red escribe, y ficha y vector salgan alineados; (4) entrenamiento por destilación a nivel de secuencia [11], la única viable cuando el profesor solo expone texto; (5) despliegue cuantizado INT4 con AWQ [20] sobre el mismo runtime ONNX que ya sirve los embeddings.

Ese entrenamiento se excluyó del alcance final. Pesaron la preparación de un corpus propio revisado, que solo podía existir una vez construido el índice, el coste de iteración y el plazo disponible; para el desarrollo se dispuso de un portátil con una RTX 3060 de 6 GB y de dos estaciones adicionales con dos RTX 3090 accesibles por SSH, y ni el tiempo de corpus ni el de iteración cabían en el calendario junto con el cierre funcional. Como referencia de escala, el informe de Qwen2.5-Coder describe un entrenamiento continuado sobre más de 5,5 billones de tokens [23]; un ajuste mediante QLoRA [24] reduce las exigencias de memoria, pero sigue exigiendo un corpus etiquetado y una evaluación que demuestre mejora frente al modelo base. No se dispone de una comparación que muestre que una red propia rendiría mejor o peor, ni de un presupuesto medido del entrenamiento descartado.

La función prevista del worker se conserva con modelos preentrenados sustituibles: el generador y el modelo de embeddings son dos piezas separadas en lugar de un único backbone, y el código propio integra, valida y controla el recorrido. La configuración de serie emplea Qwen2.5-Coder-1.5B-Instruct Q4_K_M [23] servido por llama.cpp [28] en la GPU (Vulkan) o en CPU, con una solicitud simultánea, contexto de 8 192 tokens y caché de prompts acotada, y BGE-M3 en CPU. El razonamiento del vectorizador va desactivado: su tarea es describir, no conversar, y miles de fichas no pueden esperar. El catálogo de `setup-worker.py` permite descargar modelos con revisión y SHA-256 fijos, y la paleta permite seleccionar cualquier GGUF compatible; la guía por equipo va desde Coder 0,5B sin GPU hasta Qwen3 8B [30] a 4 bits como techo para una GPU dedicada, y solo por encima, en equipos con memoria unificada, Qwen3-Coder 30B-A3B. Un modelo mayor puede

mejorar algunas descripciones, pero hay que medir calidad, latencia y memoria; la identificación del generador utiliza su nombre de archivo, y sustituir pesos con el mismo nombre requiere invalidar la caché manualmente. El principio se mantiene: el modelo propone la ficha y el programa la valida, la cita y la escribe.

4.2.8 Metodología

Tres reglas ordenaron el trabajo. **Medir antes de decidir:** los diagnósticos se confirman con datos y el tamaño de cualquier red se decidiría sobre corpus real, no por estimación. **Fases deterministas antes que aprendidas:** el indexador debe ser determinista precisamente para que la red pueda ser la última pieza. **Honestidad de evidencia:** el estudio del estado del arte etiqueta cada mecanismo (verificado adversarialmente, canónico no re-verificado, principio de diseño, cuestión abierta) y distingue las cifras autoreportadas de las propiedades deterministas de cada arquitectura. En la evaluación se distinguen cuatro niveles de afirmación: diseño, implementación inspeccionada, prueba funcional registrada y resultado experimental comparativo. Las salidas JSON y las capturas sirven como evidencia de recorridos concretos; una prueba que pasa no acredita comportamientos que no ejerce; cada evaluación registra revisión del código, modelos, corpus, preguntas, métricas y limitaciones, y los errores se conservan junto con los aciertos.

4.3 Recursos requeridos

- Portátil con RTX 3060 de 6 GB y 15 GiB de RAM utilizable, Linux (Arch) con servicios de usuario de systemd: equipo de desarrollo y de todas las pruebas registradas.
- Dos estaciones de trabajo adicionales con dos RTX 3090, accesibles por SSH: disponibles; no se atribuyen resultados de entrenamiento.
- Software libre: Rust y su ecosistema (winit, tiny-skia, softbuffer, taffy, cosmic-text, Tree-sitter, Sled), Qdrant, Neo4j Community, llama.cpp, ONNX Runtime, Docker, Python.
- Modelos preentrenados abiertos: Qwen2.5-Coder-1.5B-Instruct (GGUF Q4_K_M) y bge-m3 (BAAI).
- Acceso a modelos de lenguaje por suscripción (CLI de Claude y de Codex) y endpoints configurables.
- Xvfb y contenedores para las pruebas de ventana sin pantalla y de compatibilidad de bibliotecas.
- Fuentes primarias de investigación en abierto (arXiv y documentación pública).

El coste inicial de una instalación incluye descargas: aproximadamente 1,15 GB para el runtime y el modelo de serie del worker, además de BGE-M3 y las imágenes de los almacenes. La VRAM observada del servidor Qwen fue de unos 1 130 MiB en la prueba

registrada; no representa su pico máximo ni el consumo de todas las configuraciones. Tras una incidencia de presión de memoria durante el desarrollo, las unidades de systemd limitan la memoria del cerebro y del worker y el servidor de Qwen arranca con la caché de prompts acotada.

4.4 Presupuesto

Tabla 5. Presupuesto del proyecto

Tipo de coste	Valor	Comentarios
Horas de trabajo en el proyecto	[COMPLETAR — horas totales]	Trabajo del autor de febrero a septiembre de 2026; no han participado otras personas
Equipo técnico: portátil con RTX 3060 de 6 GB y 15 GiB de RAM	[COMPLETAR — valor de mercado] €	Equipo propio, no adquirido para el proyecto; en él se hicieron todas las pruebas registradas
Equipo técnico: dos estaciones con dos RTX 3090	[COMPLETAR — valor de mercado] €	Equipos propios accesibles por SSH; no se usaron para entrenar
Software utilizado	0 €	Rust, Sled, Qdrant, Neo4j, llama.cpp, ONNX Runtime, Python, Docker y los pesos de Qwen y BGE-M3 son de código abierto o de descarga gratuita bajo sus licencias
Suscripciones a asistentes (Claude y ChatGPT/Codex)	[COMPLETAR — gasto real por periodo] €	Usadas como agentes conectados a Quirón y como apoyo al desarrollo; los servidores compatibles y Ollama no requieren suscripción
Estudios e informes	0 €	Todas las fuentes consultadas son de acceso abierto
Materiales empleados	0 €	Sin material de laboratorio; descargas de unos 1,15 GB para el runtime y el modelo del worker, además de BGE-M3 y las imágenes de los almacenes
Electricidad y almacenamiento	[COMPLETAR — estimación, si se incluye]	Coste de la inferencia local; no se ha medido el consumo

No se presenta un coste total hasta completar las filas pendientes. La disponibilidad de software y pesos descargables no elimina las condiciones de licencia ni los costes operativos; la revisión de licencias de distribución acompaña al paquete.

4.5 Viabilidad y despliegue

La relación coste/beneficio se apoya en un desplazamiento: el gasto recurrente por token, proporcional al tamaño del repositorio y a la frecuencia de uso, se sustituye por un coste fijo de hardware local ya amortizado y un consumo mínimo de modelo grande. La sostenibilidad futura se apoya en tres propiedades del diseño: los adaptadores de modelo son intercambiables (añadir un proveedor no toca el índice), las proyecciones son reconstruibles (el sistema sobrevive a sus propios errores) y todo el conjunto es software libre ejecutable en una sola máquina. La cuantificación del ahorro en tareas completas no se ha realizado; la única medida disponible es el volumen de las fichas frente al código de referencia (apartado 4.6.4).

Existe un paquete de instalación por usuario para Linux x86_64 que prepara configuración privada, servicios y lanzador. Requiere Python, Docker, systemd de usuario y acceso a las descargas; no es un paquete offline ni una distribución certificada para cualquier Linux. El primer candidato, compilado en el equipo de desarrollo, exigía GLIBC_2.43 y no cargaba en una base Debian 13 con glibc 2.41. La compilación de entrega pasa a Ubuntu 24.04 (glibc 2.39), con imagen base fijada por digest y Rust 1.93.0, y el empaquetador rechaza símbolos superiores a esa versión; Ubuntu 22.04 se descartó porque el archivo estático de ONNX Runtime utiliza funciones de C23 que su glibc no proporciona. El paquete incluye cinco binarios (editor, cerebro, pasarela, indexador y herramienta del registro), las fuentes, la memoria y las evidencias. Los cinco binarios resuelven sus bibliotecas en Ubuntu 24.04 y Debian 13; en Ubuntu se abrió una ventana Xvfb a 1280 × 720 y se comprobó el instalador en staging, prueba que descubrió bibliotecas X11 cargadas dinámicamente que `ldd` no detecta y que se añadieron al control previo del instalador. No se certifica el ciclo completo con Docker y systemd en una máquina virtual limpia. El paquete comprobado se compiló a partir de la revisión del 10 de septiembre; el script de empaquetado permite regenerarlo desde la revisión entregada.

Los almacenes viven con la aplicación: Qdrant y Neo4j se levantan justo antes del cerebro y se paran con él, escuchan solo en la interfaz local con límites de memoria y no arrancan al encender la máquina. Cerrar la ventana permite continuar el trabajo en segundo plano, y el cerebro se apaga solo tras quince minutos sin uso, teniendo en cuenta las peticiones y los barridos activos.

4.6 Resultados del proyecto

4.6.1 Pruebas automatizadas

Los tres crates y el instalador disponen de pruebas automatizadas. La tabla recoge la ejecución final sobre la revisión entregada, después de retirar del código los adaptadores y el servicio de embeddings externo que ya no se usaban.

Tabla 6. Pruebas automatizadas de la revisión entregada

Componente	Pruebas aprobadas	Observaciones
Editor (workspace de siete crates)	329	Tres pruebas ignoradas por defecto; las que usan un servidor simulado necesitan acceso a localhost
Cerebro (- - features full)	183	Incluye mutaciones del hash v2, rechazo atómico de lotes, cuatro escritores concurrentes, corrupción, migración y recuperación tras terminar un proceso
Pasarela	12	Selección explícita de proveedor por conversación y adaptadores vigentes
Entrega (instalador)	9	Docker simulado; no acreditan una instalación limpia con bases reales

Las pruebas del cerebro no son una prueba de corte eléctrico ni de todos los fallos de disco posibles. Un error de entrada/salida después de confirmar deja un resultado incierto; un reintento con el mismo identificador se rechaza si ya estaba guardado.

4.6.2 Integración y recorridos completos

Tabla 7. Evidencias funcionales registradas

Evidencia	Qué acredita	Límite
2026-09-05/w orker-integr acion.json	Dos proyectos sintéticos: consulta, cambios, borrados, exclusión de secretos y enlaces, caché	No mide precisión en proyectos arbitrarios
2026-09-05/a gentes/resum en.json	Rondas de interfaz con Claude, Codex, servidor local y escenarios compatibles simulados	Distinguir inferencia real de transporte simulado
2026-09-05/c onsulta-codi go.json	Consultas con fuentes, control de vigencia y uso del chat	Muestra pequeña; incluye respuestas incompletas
2026-09-10/w orker-integr acion.json	Repetición sobre dos proyectos temporales: autenticación, consultas, cambios, borrados, proyecciones y ausencia de inferencia sin cambios	Equipo de desarrollo
2026-09-10/g ui/gui-edit. json	Abrir, editar, guardar, deshacer y rehacer con estados intermedios, cerrar y reabrir conservando contenido e identidad, actualizar el índice	Una ventana, un archivo
2026-09-10-e stabilidad/w orker-integr acion.json	13 comprobaciones con Qwen, BGE-M3, Qdrant y Neo4j reales, incluidos filtros de vecinos entre proyectos y modelos	Equipo de desarrollo
2026-09-10-p roveedores/	Claude y Codex desde la ventana sobre la misma función, con lectura por herramienta y fuentes verificadas	Dos rondas; no comparan rendimiento

El registro de eventos verificado el 5 de septiembre contaba 5 057 eventos con cadena válida bajo el algoritmo inicial. La herramienta `ledger_admin` se ensayó sobre una copia antes de aplicarla al servicio: conservó byte a byte los 5 284 eventos existentes y añadió el evento de anclaje, con 5 285 eventos válidos en la comprobación posterior. Una ejecución intermedia de la integración fue interrumpida por el apagado por inactividad del servicio, que detuvo sus almacenes; se conservó ese fallo y se repitió la prueba manteniendo el servicio activo.

Las dos CLI se comprobaron desde la ventana del editor sobre la misma función sintética de cuatro líneas, que duplica un entero mediante `checked_mul`. El worker produjo dos fichas, de archivo y de función, sin recurrir al analizador estructural. En ambos casos el chat recuperó las fichas con sus referencias y hash, el asistente solicitó leer el archivo mediante la herramienta del editor y devolvió `Some(14)` para la entrada siete y `None` para el máximo de `u32`. La CLI de Claude resolvió el alias `sonnet` como `claude-sonnet-5`; Codex utilizó `gpt-6-astra` con esfuerzo `xhigh`. El editor registró 12,8 y 32,8 segundos respectivamente. Al pasar de Claude a Codex no cambiaron los procesos del cerebro ni del

worker ni el archivo privado de configuración, las ventanas cerraron normalmente y el código no se modificó. El catálogo consultado con Codex CLI 0.153.0 anunciaba GPT-6 Astra, GPT-5.6 Sol, Terra y Luna, GPT-5.5 y GPT-5.3 Codex Spark: son los modelos visibles en esa cuenta y fecha, no una disponibilidad universal.

4.6.3 Diagnóstico medido de la recuperación

En julio, la investigación de por qué la recuperación de la memoria de eventos no consultaba el índice identificó cuatro causas, todas medidas: el binario del cerebro se compilaba sin sus funcionalidades opcionales, el identificador de proyecto difería entre el editor (ruta canónica) y los eventos (nombre), el filtro de proyecto se aplicaba después de la búsqueda en lugar de dentro de Qdrant, y las conversaciones anteriores reaparecían por una búsqueda de palabras clave sobre el registro. Se refutó además, midiendo, una hipótesis plausible: los 1 652 puntos de memoria personal de ámbito global no desplazaban a los del proyecto en consultas reales (los veinticinco vecinos más próximos pertenecían todos al proyecto); la hipótesis del sumidero vectorial procedía de sondear el índice con vectores aleatorios, que gravitan hacia el grupo más denso. Las correcciones deterministas de ese diagnóstico (compilación con `full` por defecto, identidad por ULID, filtro dentro de Qdrant) se aplicaron en agosto y septiembre al índice de código.

4.6.4 Evaluación exploratoria de localización

El protocolo utiliza preguntas de localización con símbolos esperados identificados en el código antes de consultar el índice. Mide si el objetivo aparece entre los cinco primeros resultados vectoriales y en el conjunto ampliado por llamadas, y registra el rango de la primera coincidencia. Una coincidencia de símbolo es un indicador de localización; no demuestra que la respuesta explique correctamente su comportamiento. Se compara además el volumen de las fichas recuperadas con el texto de los archivos de código bajo el mismo tokenizador: es una medida del material de contexto, no del coste de una tarea completa ni de la facturación de un proveedor, y responde a la idea del plan de julio de computar el volcado offline en lugar de pagarlo.

La ejecución se conserva en `docs/evidencias/2026-09-10/localizacion.json`, junto con el protocolo `docs/evaluacion/localizacion-v1.json` y el script `scripts/evaluate-index.py`. El conjunto de referencia contiene 140 archivos Rust versionados bajo `src/`, de hasta 512 KiB cada uno. La búsqueda se hizo sobre el índice del proyecto completo, con los modelos ya cargados.

Tabla 8. Resultados de la evaluación de localización sobre diez preguntas

Medida	Resultado observado
Preguntas con objetivo entre los cinco resultados directos (Hit@5)	10 de 10
Media del inverso del rango del objetivo, hasta cinco (MRR@5)	0,75
Preguntas con objetivo tras la expansión por llamadas	10 de 10; no aumenta los aciertos en esta muestra
Mediana de duración de la petición de búsqueda	0,111 s
Fichas devueltas, contando apariciones entre preguntas	75; todas coinciden con el proyecto solicitado y con el hash del archivo actual
Texto de referencia de los 140 archivos	420 881 tokens
Mediana del conjunto de fichas por pregunta, incluida expansión	2 491,5 tokens; 0,592 % del volumen de referencia

Hit@5 cuenta las preguntas cuyo símbolo esperado aparece en los cinco primeros resultados; MRR@5 premia que aparezca antes. Se empleó el tokenizador de Qwen2.5-Coder-1.5B-Instruct mediante `/tokenize`, sin tokens especiales. El informe conserva las preguntas, los objetivos, los resultados completos, los hashes del corpus y los tiempos, y no se detectaron cambios de esos archivos durante la evaluación. El volumen menor de las fichas no se presenta como un porcentaje de ahorro económico: enviar todo el código es solo una referencia de tamaño. Las preguntas proceden del desarrollo, no de un conjunto independiente; tampoco se puntuó la fidelidad de cada resumen ni se comparó el éxito de una tarea completa.

4.6.5 Fidelidad de las fichas

Una inspección de las fichas de esos objetivos encontró errores concretos en la versión v4 del worker: `collect_calls` se describía como análisis de TypeScript aunque su integración utiliza Rust; `read_file` mencionaba 1 000 caracteres cuando la constante es 24 000; y `stable_id` situaba al final dos bytes cero que el código intercala como separadores. También había descripciones que terminaban a mitad de frase. Los ejemplos y los fragmentos de contraste se conservan en `fidelidad-observaciones.json`. Esta inspección forma parte del desarrollo, no de una valoración independiente ni de una tasa de error representativa, y confirma que la firma y el código deben prevalecer sobre el texto generado.

La versión v5 de las fichas, descrita en el apartado 4.2.3, se probó sobre una muestra de ocho funciones que comprendía los tres ejemplos problemáticos y cinco funciones sintéticas adicionales. Siete descripciones fueron aceptadas y una se sustituyó por una ficha estructural al no terminar una frase completa. Las citas y los hashes coincidieron con las

fuentes, y los tres errores anteriores no reaparecieron. Las descripciones todavía pueden omitir ramas, unidades o efectos. No se establece una tasa de fidelidad semántica ni se extrapola el Hit@5 de v4 a v5 sin repetir la evaluación.

4.6.6 Plan de pruebas de julio y grado de ejecución

Tabla 9. Plan de pruebas previsto en julio y grado de ejecución al cierre

Prueba prevista	Estado	Qué se hizo
Reducción de consumo: tokens por tarea con índice frente a volcado	Parcial	Solo la referencia de volumen del apartado 4.6.4; no se midieron tareas completas
Calidad de recuperación contra un conjunto etiquetado	Parcial	Diez preguntas de localización con objetivos fijados de antemano; sin conjunto independiente
Aislamiento: ninguna consulta devuelve unidades de otro proyecto	Cumplida	Comprobación binaria en las integraciones del 5 y del 10 de septiembre, incluida la expansión por grafo
Reconstruibilidad : borrar índice y grafo y re proyectar produce el mismo contenido	Parcial	Reparación desde la caché y reindexación desde los archivos; no desde el registro
Fidelidad de fichas sobre un conjunto etiquetado	Parcial	Inspección de fichas v4 y muestra de ocho funciones con v5; sin tasa representativa
Comparativa de vías de acceso al modelo profesor (suscripción frente a API)	No realizada	Sin entrenamiento no hubo corpus que generar
Curva de escalado del consumo sobre repositorios de tamaño creciente	No realizada	Queda como línea futura con el método de cómputo offline ya disponible

Capítulo 5. DISCUSIÓN

El profesor sin logits y la decisión de no entrenar. El acceso a los modelos grandes es por suscripción: el profesor devuelve texto, no distribuciones. Eso descarta la destilación clásica con temperatura y las variantes on-policy, y deja la destilación a nivel de secuencia como única vía matemáticamente honesta [11]; se asume el matiz de que su justificación es la tratabilidad, no una garantía de que la moda del profesor concentre la probabilidad. La vía por suscripción tampoco permite controlar la temperatura del profesor, que sí controla el acceso por API. Con ese marco claro, la decisión de septiembre fue no abrir la fase de entrenamiento: el corpus solo podía existir después del índice, y el índice, el editor y los proveedores tenían que funcionar de punta a punta antes del cierre. Los modelos preentrenados cumplen hoy la función prevista para la red con una calidad suficiente para localizar; la red propia queda como mejora, no como sostén, exactamente como fijaba la planificación.

El alcance económico de la validación. La hipótesis del trabajo se manifestaría con mayor claridad justo donde no puede pagarse la prueba: un proyecto industrial con miles de archivos, donde una sola tarea resuelta por volcado costaría del orden de miles de euros en tokens. Esa barrera no es solo una limitación del estudio: es la evidencia del problema que este trabajo ataca. Por eso el plan de julio proponía computar el consumo del volcado offline con un tokenizador, sin realizar la petición, y repetir la medida sobre repositorios de tamaño creciente para obtener una curva de escalado. La versión entregada aplica la primera idea sobre el propio repositorio (fichas del 0,6 % frente al volcado de 140 archivos) y deja la curva como línea futura. Contar tokens no demuestra calidad equivalente: una evaluación de tareas debe contabilizar instrucciones, fichas, lecturas adicionales, historial, resultados de herramientas y respuesta, y no se presenta el coste de una prueba que no se realizó como evidencia de ahorro.

Lo que enseñaron el diagnóstico y la auditoría. Tres hipótesis plausibles sobre el fallo de recuperación de julio resultaron falsas al medirse, y la causa raíz (compilación sin funcionalidades) era invisible desde la conducta del sistema. La lección quedó incorporada: ningún diagnóstico se acepta sin medición, y las sondas sintéticas pueden fabricar patologías que no existen ante consultas reales. La revisión de septiembre repitió la lección en otro plano: contrastar la memoria con el código encontró que el hash del registro no cubría todos los campos, que las escrituras no eran atómicas y que la expansión por el grafo no repetía el filtro de proyecto; las tres cosas se corrigieron y se probaron. Y las fichas v4, que pasaban el esquema, contenían errores de contenido que solo aparecieron al leerlas junto al código; la respuesta fue exigir citas que el programa copia y verifica, no confiar más en el modelo.

Cambios respecto al planteamiento inicial. La memoria de eventos y el índice de código compartían colección y ciclo de vida en el diseño de julio; el trabajo los separó conceptual y físicamente: la promoción gobierna la memoria del agente (afirmaciones con incertidumbre),

mientras que una unidad de código no tiene incertidumbre, existe o no existe y su hash coincide o no, y se escribe y retira según el hash. De ahí que el índice se mantenga desde los archivos y no desde el registro. El segundo cambio es el ya discutido: modelos preentrenados en lugar de red propia, con generador y embeddings separados en vez de un único backbone. El tercero es que el servicio de embeddings pasó de ser un proceso aparte a ejecutarse dentro del cerebro, y que el reranker previsto no se usa en el recorrido del índice.

Limitaciones. El índice de código depende de los archivos y de la caché local; el registro no contiene todo lo necesario para reconstruirlo. Las relaciones de llamadas emplean aproximaciones y no constituyen un análisis semántico completo. El hash comprueba la correspondencia con el archivo; no valida la semántica del resumen, y la similitud no equivale a identidad de comportamiento. No hay reranker, presupuesto de contexto, detector de duplicados ni resúmenes por carpeta. Los resultados de aislamiento sobre dos proyectos son evidencia acotada, no una prueba formal de todas las consultas posibles. El registro v2 no ha sido probado frente a pérdida de alimentación ni resiste a un actor capaz de reescribir toda la base y su cabecera, al no existir una raíz de confianza externa. El modelo de uso evaluado es un escritorio local de un solo usuario; la instalación no está certificada en una máquina limpia y las dos rondas con proveedores no permiten comparar rendimiento.

Capítulo 6. CONCLUSIONES

6.1 Conclusiones del trabajo

Respecto al objetivo general, el trabajo ha construido y verificado un editor nativo que mantiene, mientras se trabaja, un índice de código por proyecto: fichas de archivos y de lógica Rust redactadas por un modelo local pequeño, vectorizadas y proyectadas en Qdrant y Neo4j, con referencias comprobables contra el código vigente y aisladas por identidad de proyecto. El asistente elegido, Claude, Codex, un servidor compatible u Ollama, recibe esas fichas y puede leer el código mediante las herramientas del editor, bajo la misma guardia que confina al propio editor. El registro inmutable de eventos, la infraestructura de servicios y la salida a modelos sin dependencia de un proveedor están contruidos y probados.

La pieza aprendida cambió de naturaleza: la red propia no se entrenó, y el worker usa modelos preentrenados sustituibles. La arquitectura que situaba la red como última pieza demostró su valor precisamente ahí: permitió cerrar un sistema útil sin ella, diagnosticar con mediciones, corregir sin reescribir el pasado y acotar el riesgo de la pieza aprendida a errores reversibles. El estudio matemático conserva su valor como exploración fundamentada de la red futura.

La hipótesis central, que el índice reduce el contexto manteniendo la calidad de tareas completas, sigue abierta: la localización funciona en la muestra evaluada y las fichas son una fracción pequeña del código, pero el ahorro por tarea y la prevención de duplicados no se han medido. El grado de cumplimiento de cada objetivo se recoge en el Capítulo 3 para que los resultados puedan evaluarse sin confundir el prototipo con la totalidad del diseño inicial.

6.2 Conclusiones personales

[COMPLETAR — reflexión personal del autor. Texto base del borrador de julio, para personalizar: Este proyecto ha sido un año de aprendizaje acelerado: de usuario de asistentes de programación a diseñador de la infraestructura que los alimenta. Trabajar a diario con modelos de lenguaje, siendo a la vez su primer usuario, su crítico y su arquitecto, me ha enseñado más sobre atención, memoria y evidencia que cualquier asignatura aislada: la disciplina de medir antes de afirmar, de distinguir lo verificado de lo plausible y de diseñar sistemas cuyo peor error sea reversible.]

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

- **Red obrera entrenada:** generar el corpus de destilación a partir del índice ya existente, evaluar LoRA/QLoRA o destilación a nivel de secuencia frente al modelo base, y comparar un profesor por API con temperatura controlada o un profesor local con logits.
- **Validación a escala:** curva de escalado del consumo sobre repositorios de tamaño creciente con el cómputo offline de tokens, y comparación de tareas completas con y sin índice en un proyecto real de gran tamaño.
- **Reconstrucción desde el registro:** registrar cambios de código suficientes para reproyectar el índice desde evidencia histórica y probar su equivalencia lógica; ampliar las pruebas del registro v2 a fallos de almacenamiento y pérdida de alimentación, y estudiar puntos de control externos.
- **Grafo y recuperación:** resolver módulos, tipos e importaciones; incorporar el reranker y el presupuesto de contexto con el tokenizador del asistente; ampliar las pruebas de aislamiento a más repositorios.
- **Consistencia activa:** detectar candidatos a lógica duplicada mediante estructura y similitud, con confirmación humana y métricas de falsos positivos; inferir motivos de cambio con evidencia; presentar responsabilidades agregadas por carpeta.
- **Worker:** ampliar la extracción sintáctica a otros lenguajes, comparar generadores y cuantizaciones por fidelidad, latencia y memoria, e identificar los pesos del generador por hash y no por nombre.
- **Distribución:** certificar la instalación en máquinas limpias, empaquetar como ApplImage o Flatpak y estudiar la compilación para Windows y para ARM.
- **Integración:** exponer el índice como servidor MCP para otros clientes, importar sesiones archivadas de otros asistentes como evidencia del registro, y admitir consultas multi-proyecto con lista explícita de identificadores, nunca por ausencia de filtro.

Capítulo 8. REFERENCIAS

Los informes técnicos de modelos se citan como resultados de sus autores; no son mediciones reproducidas en este trabajo.

[1] DeepSeek-AI, "DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model", arXiv:2405.04434, 2024.

[2] DeepSeek-AI, "DeepSeek-V3 Technical Report", arXiv:2412.19437, 2024.

[3] DeepSeek-AI, "Native Sparse Attention: Hardware-Aligned and Natively Trainable Sparse Attention", arXiv:2502.11089, 2025.

[4] MiniMax, "MiniMax-01: Scaling Foundation Models with Lightning Attention", arXiv:2501.08313, 2025.

[5] MiniMax, "MiniMax-M1", arXiv:2506.13585, 2025.

[6] Ling Team, "Every Attention Matters: An Efficient Hybrid Architecture for Long-Context Reasoning", arXiv:2510.19338, 2025. <https://arxiv.org/abs/2510.19338>

[7] Y. Pan, Y. An, Z. Li, Y. Chou, R. Zhu, X. Wang, M. Wang, J. Wang y G. Li, "Scaling Linear Attention with Sparse State Expansion", arXiv:2507.16577, 2025. <https://arxiv.org/abs/2507.16577>

[8] DeepSeek-AI, "DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models", arXiv:2401.06066, 2024.

[9] L. Wang, H. Gao, C. Zhao, X. Sun y D. Dai, "Auxiliary-Loss-Free Load Balancing Strategy for Mixture-of-Experts", arXiv:2408.15664, 2024.

[10] G. Hinton, O. Vinyals, J. Dean, "Distilling the Knowledge in a Neural Network", arXiv:1503.02531, 2015.

[11] Y. Kim, A. M. Rush, "Sequence-Level Knowledge Distillation", arXiv:1606.07947, 2016.

[12a] Y. Gu et al., "MiniLLM: Knowledge Distillation of Large Language Models", arXiv:2306.08543, 2023.

[12b] R. Agarwal et al., "On-Policy Distillation of Language Models (GKD)", arXiv:2306.13649, 2023.

[12c] T. Wu, C. Tao, J. Wang, R. Yang, Z. Zhao y N. Wong, "Rethinking Kullback-Leibler Divergence in Knowledge Distillation for Large Language Models", arXiv:2404.02657, 2024. <https://arxiv.org/abs/2404.02657>

[13] A. van den Oord, Y. Li, O. Vinyals, "Representation Learning with Contrastive Predictive Coding", arXiv:1807.03748, 2018.

- [14] L. Wang et al., "Improving Text Embeddings with Large Language Models (e5-mistral)", arXiv:2401.00368, 2024.
- [15] D. Kryvosheieva, S. Sturua, M. Günther y H. Xiao, "Efficient Code Embeddings from Code Generation Models", arXiv:2508.21290, 2025. <https://arxiv.org/abs/2508.21290>
- [16] A. Kusupati et al., "Matryoshka Representation Learning", arXiv:2205.13147, 2022.
- [17] Qdrant, "Qdrant — Vector Database", documentación. <https://qdrant.tech> (consultado en septiembre de 2026).
- [18] Neo4j, "Neo4j Graph Database", documentación. <https://neo4j.com> (consultado en septiembre de 2026).
- [19] BAAI, modelos bge-m3 y bge-reranker-v2-m3. <https://huggingface.co/BAAI> (consultado en septiembre de 2026).
- [20] J. Lin et al., "AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration", arXiv:2306.00978, 2023.
- [21] E. Frantar et al., "GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers", arXiv:2210.17323, 2022.
- [22] Microsoft, "ONNX Runtime", documentación. <https://onnxruntime.ai> (consultado en septiembre de 2026).
- [23] B. Hui et al., "Qwen2.5-Coder Technical Report", arXiv:2409.12186, 2024. <https://arxiv.org/abs/2409.12186>
- [24] T. Dettmers, A. Pagnoni, A. Holtzman y L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs", arXiv:2305.14314, 2023. <https://arxiv.org/abs/2305.14314>
- [25] F. Zhang et al., "RepoCoder: Repository-Level Code Completion Through Iterative Retrieval and Generation", arXiv:2303.12570, 2023. <https://arxiv.org/abs/2303.12570>
- [26] W. Liu et al., "GraphCoder: Enhancing Repository-Level Code Completion via Code Context Graph-based Retrieval and Language Model", arXiv:2406.07003, 2024. <https://arxiv.org/abs/2406.07003>
- [27] S. Ouyang et al., "RepoGraph: Enhancing AI Software Engineering with Repository-level Code Graph", arXiv:2410.14684, 2024. <https://arxiv.org/abs/2410.14684>
- [28] ggml-org, "llama.cpp server", documentación y código. <https://github.com/ggml-org/llama.cpp/tree/master/tools/server> (consultado en septiembre de 2026).
- [29] J. Chen et al., "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation", arXiv:2402.03216, 2024. <https://arxiv.org/abs/2402.03216>

[30] Qwen Team, "Qwen3 Technical Report", arXiv:2505.09388, 2025. <https://arxiv.org/abs/2505.09388>

[31] M. Brunsfeld et al., "Tree-sitter: an incremental parsing system for programming tools", documentación y código. <https://tree-sitter.github.io> (consultado en septiembre de 2026).

[32] T. Kemp et al., "sled: an embedded database", código. <https://github.com/spacejam/sled> (consultado en septiembre de 2026).

Capítulo 9. ANEXOS Y TRAZABILIDAD

- **Anexo A — Estudio de alternativas para la red obrera:** se incorpora a continuación de este capítulo desde `docs/ESTUDIO_RED_OBRERA.md`. Se conserva como propuesta inicial, con una nota que aclara su relación con la implementación.
- **Anexo B — Informes técnicos de cierre:** `docs/CIERRE_TFM_2026-09-10.md` (contraste entre código y memoria, con los límites técnicos encontrados), `docs/ESTABILIZACION_2026-09-10.md` (correcciones del registro, de las fichas y del paquete) y `docs/CODEX_EN_QUIRON_2026-09-10.md` (integración de Codex).
- **Anexo C — Manual e instalación:** `docs/MANUAL.md` (manual de uso, accesible desde la aplicación), `docs/GUIA_EVALUACION.md` (guía para evaluar la aplicación en otro equipo), `docs/WORKER_Y_PROVEEDORES.md` (contrato del worker y de las conexiones) y `deploy/LINUX.md` (requisitos y límites del paquete Linux). El código es la referencia para resolver cualquier discrepancia con la documentación.
- **Anexo D — Evidencias:** `docs/evidencias/2026-09-05/` para las pruebas de la primera integración y `docs/evidencias/2026-09-10*/` para las del cierre. Los archivos de cada ejecución indican su alcance; una captura o una simulación no se presenta como ensayo de instalación limpia.
- **Anexo E — Fuentes y artefactos:** repositorio de entrega [COMPLETAR — URL], revisión etiquetada entrega-tfm. Este Markdown es la fuente de las exportaciones DOCX y PDF, generadas con `scripts/export-memory.py`; el paquete binario se construye con `scripts/package-linux-portable.sh` y lleva su inventario de hashes.

Anexo A. Estudio de alternativas para la red obrera

Estudio: la matemática de la red obrera de Quirón

Algoritmos y ecuaciones de los LLM recientes, y cómo reutilizarlos en nuestro worker
TFM Quirón · Anexo A de la memoria · 10 de julio de 2026

Nota sobre el alcance. Este estudio recoge las alternativas que analicé para el diseño inicial de la red obrera. La versión entregada de Quirón usa modelos preentrenados descargables (Qwen como generador de fichas y BGE-M3 para los embeddings); el backbone que aquí se propone no llegó a entrenarse ni a exportarse a ONNX. Las etiquetas de «verificación adversarial» describen el procedimiento que seguí en julio al contrastar las fuentes; no sustituyen una reproducción experimental. El índice de código de la versión final se mantiene desde los archivos y una caché local, no como reconstrucción completa desde el registro de eventos. Los resultados vigentes están en la memoria.

Este documento extrae **la matemática** de los mecanismos con los que se han construido los LLM recientes —no compara modelos— y explica, para cada uno: **(a)** la ecuación esencial, **(b)** por qué funciona, **(c)** la referencia de arXiv, y **(d)** cómo se aplica a nuestro worker. El objetivo es reutilizar esas matemáticas en **una sola red pequeña, local, destilable y exportable a ONNX/Rust**.

Cómo leer las etiquetas de evidencia

Fue un barrido de fuentes primarias con verificación adversarial (tres pasadas, ~75 afirmaciones sobre >40 fuentes). Cada mecanismo lleva una etiqueta:

- **Verificado** — confirmado 3-0 en la verificación adversarial de este barrido.
- **Fundamental** — matemática canónica establecida (referencia original); **no re-verificada** adversarialmente aquí, pero es estándar de libro.
- **Principio de diseño** — la idea es reutilizable, pero **no la desplegamos tal cual** por fricción con ONNX/Rust o por tamaño.
- **Cuestión abierta** — debate activo en la literatura; se declara como tal.

Honestidad metodológica: las cifras de los *technical reports* (−93,3 % de KV-cache, 25 % de FLOPs, «degradación negligible») son **autoreportadas** por sus autores. Las de complejidad ($O(n \cdot d^2)$, tamaño de estado $d \times d$) son propiedades deterministas de la arquitectura. Se distingue donde importa.

0. Marco del diseño inicial

El diseño inicial proponía un daemon asociado al proyecto, con dos proyecciones —vectores en Qdrant y grafo en Neo4j— reconstruibles desde un registro de cambios. Una sola red pequeña habría aportado descripciones y representaciones. Ese diseño no se realizó íntegramente: la versión de cierre usa archivos y caché local, Qwen para describir y BGE-M3 para vectorizar. Las limitaciones de la cadena de hashes se explican en §4.2.1 de la memoria. El worker no ejecuta herramientas, pero una descripción incorrecta sí puede inducir errores en el asistente que la recibe; reconstruir el grafo no valida esa descripción.

Sus tres prioridades ordenan a qué sirve cada matemática de abajo: **(1) aislar por proyecto, (2) enlazar/recuperar vectores a escala, (3) etiquetar qué hace cada archivo sin alucinar.**

FAMILIA 1 — Atención eficiente y gestión del KV-cache

El problema: la atención estándar cuesta $O(n^2 \cdot d)$ y su KV-cache crece **lineal** con la longitud. Tres formas de romperlo.

1.1 Multi-head Latent Attention (MLA) — comprimir el KV · Verificado

(a) Ecuación. En vez de cachear K y V por cabeza, se comprimen juntos a un latente de bajo rango y se reconstruyen al vuelo:

$$\begin{array}{ll} c_t^{KV} = W^{DKV} \cdot h_t & \text{con } d_c \ll d_h \cdot n_h \quad (\text{down-projection}) \\ k_t^C = W^{UK} \cdot c_t^{KV} & v_t^C = W^{UV} \cdot c_t^{KV} \quad (\text{up-projections}) \\ k_t^R = \text{RoPE}(W^{KR} \cdot h_t) & (\text{clave posicional RoPE, desacoplada y compartida}) \end{array}$$

Solo se **cachea** c_t^{KV} (**pequeño**) y la **clave RoPE** k_t^R , no K/V completos.

(b) Por qué funciona. K y V de un token viven en un subespacio de dimensión mucho menor que $d_h \cdot n_h$; una proyección de bajo rango los captura casi sin pérdida. El RoPE se saca aparte porque su rotación **no puede absorberse** en las up-projections (depende de la posición). Resultado: **-93,3 %** de KV-cache respecto a DeepSeek-67B con calidad comparable a MHA.

(c) DeepSeek-V2 arXiv:2405.04434; DeepSeek-V3 arXiv:2412.19437.

(d) Aplicación al worker. Son solo *matmuls* → **exportable a ONNX**. Un KV-cache pequeño abarata el daemon en inferencia autoregresiva en Rust. El truco de absorción de matrices reduce memoria. (*Matiz : la variante con absorción y RoPE desacoplado no es trivial de exportar; el principio low-rank sí.*)

1.2 Native Sparse Attention (NSA) — atención dispersa entrenable · Verificado

(a) Ecuación. Tres ramas combinadas por un *gate* aprendido:

$$o_t^* = \sum_{c \in \{cmp, slc, win\}} g_t^{\{c\}} \cdot \text{Attn}(q_t, K_t^{\{c\}}, \tilde{V}_t^{\{c\}})$$

$$g_t^{\{c\}} = \text{sigmoid}(\text{MLP}(x_t)) \in [0,1]$$

- **cmp**: compresión gruesa de bloques de tokens (contexto global barato).
- **slc**: selección fina de los **top-n bloques** más relevantes.
- **win**: ventana deslizante (contexto local reciente).

Truco clave: los **scores** de selección salen **gratis** de la rama de compresión, $p_t^{\{cmp\}} = \text{softmax}(q_t^T K_t^{\{cmp\}})$, y se reutilizan para rankear los bloques.

(b) Por qué funciona. Es **entrenable end-to-end** (el *gate* es diferenciable), no una poda solo-inferencia; y es *hardware-aligned* (carga bloques KV contiguos para GQA, aprovechando Tensor Cores).

(c) arXiv:2502.11089 (DeepSeek, ACL 2025 best paper).

(d) Aplicación al worker. El **gating diferenciable de ramas** es reutilizable: permite atender selectivamente a los vectores de archivos relacionados dentro de un proyecto **sin coste cuadrático**. La selección top-n sirve a la prioridad 2.

1.3 Atención lineal / lightning + SSE — estado de tamaño fijo · Verificado

(a) Ecuación. El «truco del producto por la derecha» reordena la asociatividad:

$$O = \text{Norm}((Q K^T) V) \rightarrow O = \text{Norm}(Q (K^T V)) \quad O(n^2 \cdot d) \rightarrow O(n \cdot d^2)$$

La asociatividad anterior se refiere al producto sin una no linealidad entre QK^T y V : no permite mover la softmax de la atención convencional. Una formulación causal requiere además su máscara o recurrencia correspondiente.

En forma recurrente con decaimiento, el estado es una matriz **d×d de tamaño fijo**:

$$kv_t = \lambda \cdot kv_{\{t-1\}} + k_t^T v_t \quad o_t = q_t \cdot kv_t$$

(b) Por qué funciona. $K^T V$ es un estado $d \times d$ que **no crece con la longitud**: coste **constante por paso** en inferencia. Lo que se pierde es *retrieval* asociativo (comprimir a estado fijo difumina). Por eso se **hibrida**: 1 bloque de atención completa cada 7 lineales (7:1). **SSE** (arXiv:2507.16577) mitiga la pérdida con una actualización de estado **top-k dura** (filas dispersas) que reduce la interferencia entre informaciones y **desacopla la capacidad de estado del nº de parámetros**.

(c) MiniMax-01 arXiv:2501.08313; MiniMax-M1 arXiv:2506.13585; Ring-linear arXiv:2510.19338; SSE arXiv:2507.16577.

(d) Aplicación al worker — la pieza más importante de esta familia. El estado recurrente $d \times d$ es **directamente reutilizable y exportable a ONNX**: da un **encoder de coste constante por token**, ideal para un daemon que procesa archivos **en streaming** sin re-materializar matrices $n \times n$. Para «enlazar a escala» (prioridad 2) conviene un backbone

mayormente lineal con pocas capas de atención completa. El top-k duro de SSE ayuda a la prioridad 3 (no mezclar lógicas de archivos distintos → menos alucinación). *(el kernel lightning I/O-aware con tiling no se reproduce fácil en Rust; se toma la forma recurrente, no el kernel.)*

FAMILIA 2 — Mezcla de expertos (MoE) y enrutado

2.1 DeepSeekMoE: experto compartido + expertos de grano fino · Verificado

(a) Ecuación.

```
h_t' = u_t + Σ_{i=1}^{N_s} FFN_i^{shared}(u_t) + Σ_{i=1}^{N_r} g_{i,t} · FFN_i^{routed}(u_t)
s_{i,t} = sigmoid(u_t^T e_i)                                (afinidad token-experto)
g_{i,t} = normaliza( s_{i,t} si i ∈ TopK_r, si no 0 )
```

DeepSeek-V3: $N_s=1$ compartido, $N_r=256$ enrutados, $K_r=8$ activos → **671 B totales, 37 B activados por token.**

(b) Por qué funciona. El experto **compartido** captura lo común; los de **grano fino** se especializan. Así se **desacopla la capacidad (parámetros) del cómputo por token.**

(c) DeepSeekMoE arXiv:2401.06066; DeepSeek-V2/V3 arXiv:2405.04434 / 2412.19437.

(d) Aplicación al worker. Principio de diseño, no despliegue. Los modelos MoE de la escala citada exceden el equipo disponible; no se concluye que todo MoE sea inviable. Su *routing* requiere estudiar la exportación a ONNX/Rust. El patrón «**una cabeza compartida + cabezas especializadas por tipo de lógica**» inspira la estructura de **nuestra única red** sin necesidad de *routing* disperso.

2.2 Balanceo de carga SIN pérdida auxiliar · Verificado

(a) Ecuación. Se añade un **sesgo por experto** b_i solo a la **decisión** de enrutado, nunca al peso de mezcla:

```
enruta i <=> (s_{i,t} + b_i) ∈ TopK                (el peso sigue siendo s_{i,t}, sin sesgo)
b_i ← b_i - γ si el experto i está sobrecargado
b_i ← b_i + γ si está infrautilizado                (γ = 0.001)
```

(b) Por qué funciona. La pérdida auxiliar clásica inyecta **gradientes de interferencia** que dañan el objetivo de lenguaje. Aquí el sesgo cambia **qué** experto se elige sin contaminar **cuánto** pesa, así el balanceo **no altera el objetivo**. Eleva el techo de rendimiento.

(c) Loss-Free Balancing arXiv:2408.15664; DeepSeek-V3 arXiv:2412.19437.

(d) Aplicación al worker. Si la red usa varias cabezas, este **control por sesgo** es un *feedback loop* barato para repartir carga **sin término de pérdida extra** — más simple de implementar y de exportar.

FAMILIA 3 — Destilación profesor → estudiante

Hilo conductor: **nuestro profesor se accede por login (Codex/Claude), sin API de pago y sin logits**. La pregunta matemática es: ¿qué destilación es posible si solo tenemos el **texto** que devuelve el profesor?

3.1 KD clásica (Hinton): *soft targets* con temperatura · Fundamental

(a) Ecuación.

$$L = (1 - \alpha) \cdot \text{CE}(y, \sigma(z_s)) + \alpha \cdot T^2 \cdot \text{KL}(\sigma(z_t / T) \parallel \sigma(z_s / T))$$

(b) **Por qué funciona.** La temperatura T **suaviza** el *softmax* del profesor y expone su «conocimiento oscuro» (qué clases considera parecidas). El factor T^2 compensa que los gradientes del término *soft* escalan como $1/T^2$, para que su magnitud iguale la del término *hard*.

(c) Hinton et al. arXiv:1503.02531. (no re-verificado en este barrido; fórmula canónica.)

(d) **Aplicación al worker. No aplicable directamente:** exige los **logits** del profesor z_t , que un profesor por login **no expone**.

3.2 Sequence-Level KD — la vía viable sin logits · Verificado

(a) **Ecuación.** El objetivo exacto suma sobre todas las secuencias (intratable); se aproxima por la **moda** del profesor, hallada con *beam search* $\hat{y}$:

$$L_{\{\text{SEQ-KD}\}} = - \sum_{\{t\}} q(t|s) \cdot \log p(t|s) \approx - \log p_s(t = \hat{y} | s)$$

Es decir: **entrenar al estudiante con cross-entropy sobre el TEXTO que genera el profesor.**

(b) **Por qué funciona.** Reduce la destilación a *maximum likelihood* sobre las respuestas del profesor. Procedimiento: (1) el profesor genera, (2) recoges su texto, (3) entrenas al estudiante con CE sobre ese corpus. **Solo necesita texto.** (Matiz honesto: la idea de que «la moda captura casi toda la masa» fue **refutada 0-3** en la verificación; el método se sostiene por **tratabilidad**, no porque esté probado que concentra la probabilidad.)

(c) Kim & Rush arXiv:1606.07947.

(d) **Aplicación al worker. Directamente reutilizable — es nuestra vía.** Es exactamente el subcaso *off-policy por respuestas* que un profesor por login sí permite. El estudiante puede ser ~10× más pequeño/rápido con poca pérdida.

3.3 Reverse-KL (MiniLLM) y GKD — por qué NO nos sirven · Verificado

- **MiniLLM** minimiza el **KL inverso** $KL(q_{\text{estudiante}} \parallel p_{\text{profesor}})$, *mode-seeking* (evita que el estudiante ponga masa donde el profesor casi no la tiene). Su gradiente es un **policy-gradient tipo REINFORCE**: $\nabla_{\theta} L = E_{\{x \sim q_s\}} [\nabla_{\theta} \log q_s(x) \cdot (\log q_s(x) - \log p_t(x))]$. Es **on-policy** y necesita **p_t token a token** → no viable solo con texto. arXiv:2306.08543.
- **GKD** generaliza con un objetivo mixto ponderado por λ ($\lambda=0$ off-policy sobre datos fijos; $\lambda=1$ on-policy sobre lo que genera el estudiante), pero **requiere los logits del profesor** sobre esas secuencias. no viable sin logits. El **único subcaso** que sobrevive sin logits es $\lambda=0$ con *targets* = secuencias del profesor... que **degenera en Sequence-Level KD**. arXiv:2306.13649.

3.4 Matiz: ¿reverse-KL es realmente mejor? · Cuestión abierta

La dicotomía *mode-seeking* (reverse) vs *mode-averaging* (forward) **presupone** distribuciones continuas y estudiante unimodal. En LLM las distribuciones son **discretas** (*softmax* sobre vocabulario) y q no es unimodal, así que la motivación de MiniLLM está **en disputa**: forward y reverse KL **comparten el mismo óptimo** $q_{\theta} = p$. Conclusión práctica: **no sobre-invertir en reverse-KL**; para un worker destilado solo con respuestas, **Sequence-Level KD (forward implícito por MLE) es lo defendible**. arXiv:2404.02657 (COLING 2025).

FAMILIA 4 — Cuantización y representación

4.1 AWQ — cuantizar protegiendo canales por activación · Verificado

(a) **Ecuación.** Reescalado equivalente por canal (sin *mixed precision*):

$$Wx \approx Q(W \cdot s) \cdot (x / s) \quad (s > 1 \text{ en los canales salientes})$$

$$s^* = \operatorname{argmin}_s \| Q(W \cdot s)(x / s) - Wx \|$$

(b) **Por qué funciona.** El error relativo de redondeo de un canal escala como $1/s$; subir s en los canales **salientes** reduce su error. Y los canales importantes se identifican por la **magnitud de la ACTIVACIÓN**, no del peso (seleccionar por peso rinde casi como al azar). Ej.: OPT-6.7B, proteger 1 % por activación baja la perplejidad 23.54 → 11.36. Es **PTQ**: no reentrena.

(c) AWQ arXiv:2306.00978 (MLSys 2024 best paper).

(d) **Aplicación al worker.** **Directamente reutilizable** para cuantizar a INT4 el backbone del worker y **caber y correr** en 48 GB / producción.

4.2 GPTQ — cuantización PTQ de segundo orden · Verificado

(a) **Ecuación.** Reconstrucción por capa con información del Hessiano (OBS):

$$\underset{\delta_F}{\operatorname{argmin}}_{\{\hat{W}\}} \|W X - \hat{W} X\|^2 \quad H_F = 2 \cdot X_F X_F^T$$

$$\delta_F = - (w_q - \operatorname{quant}(w_q)) / [H_F^{-1}]_{qq} \cdot (H_F^{-1})_{:,q} \quad (\text{redistribuye el error})$$

(b) **Por qué funciona.** La información de segundo orden **redistribuye el error de redondeo** a los pesos aún no cuantizados. Como en capas grandes el **orden importa poco**, se cuantizan todas las filas en el mismo orden $\rightarrow$ coste $O(d \cdot \text{col}^2)$ en vez de por peso. Cuantiza GPT-175B a 3-4 bits en ~ 4 GPU-h.

(c) GPTQ arXiv:2210.17323 (ICLR 2023).

(d) **Aplicación al worker.** Alternativa/complemento de AWQ para PTQ del backbone.

4.3 InfoNCE — la pérdida que da buenos embeddings · Fundamental

(a) **Ecuación.**

$$L = -\log \left[\exp(\operatorname{sim}(q, k^+)/\tau) / \sum_i \exp(\operatorname{sim}(q, k_i)/\tau) \right]$$

(b) **Por qué funciona.** Acerca el ancla q a su positivo k^+ y la aleja de los negativos k_i (los demás del *batch*). La temperatura τ controla cuánto se castiga a los negativos difíciles. Es aprendizaje contrastivo estándar.

(c) van den Oord et al. (CPC) arXiv:1807.03748. (*canónico, no re-verificado.*)

(d) **Aplicación al worker.** Base para entrenar los **embeddings de código 1024-dim** que pueblan Qdrant (prioridad 2). Positivos = pares código $\leftrightarrow$ resumen o código $\leftrightarrow$ código equivalente.

4.4 Last-token pooling — de decoder causal a embedding · Fundamental

(a) **Idea.** En un *decoder* causal, el **estado del último token** $e = h_L$ resume la secuencia, porque la atención causal deja que ese token «vea» todos los anteriores. Es cómo modelos como e5-mistral / gte-Qwen / jina-code-embeddings producen un vector desde un backbone autoregresivo.

(c) jina-code-embeddings arXiv:2508.21290; e5-mistral arXiv:2401.00368. (*no re-verificado.*)

(d) **Aplicación al worker.** Permite **reutilizar el mismo backbone destilado** tanto para etiquetar (generar) como para vectorizar (embedding), alineando ambas representaciones. Cuando tocamos un archivo, su vector = h_L de su resumen.

4.5 Matryoshka (MRL) — un vector, muchas dimensiones · Fundamental

(a) **Ecuación.** Se entrena con la suma de la pérdida sobre **prefijos anidados** del vector:

$$L = \sum_{m \in \{8, 16, 32, \dots, 1024\}} c_m \cdot L_{\text{task}}(z_{1:m})$$

(b) Por qué funciona. Al forzar que **cada prefijo** $z_{\{1:m\}}$ sea por sí solo un buen embedding, la información se ordena por importancia en las primeras dimensiones. Así el **mismo vector se puede truncar** a 256 o 64 dim **sin reentrenar**, perdiendo poca calidad.

(c) MRL arXiv:2205.13147. *(no re-verificado.)*

(d) Aplicación al worker. Vectores **1024-dim truncables**: búsqueda barata en dimensión baja + reranking en dimensión alta. Escala la prioridad 2 sin duplicar índices.

Síntesis — la red obrera propuesta

Combinando **solo lo reutilizable**, una **única red pequeña** con esta forma:

- **Backbone híbrido mayormente lineal** (estado recurrente $d \times d$, §1.3) con **pocas capas de atención completa** (ratio $\sim 7:1$). El componente recurrente tiene coste constante por paso para dimensiones fijas; el modelo completo conserva la dependencia de la longitud en sus capas de atención completa. Su exportación y rendimiento en ONNX requieren implementación y medición.
- **Una cabeza compartida + cabezas por tipo de lógica** (inspiración del experto compartido de §2.1, *sin routing* MoE real) para etiquetar.
- **Embeddings de código con InfoNCE (§4.3) + last-token pooling (§4.4) + Matryoshka a 1024-dim (§4.5)** → una representación que podría almacenarse en Qdrant. Compartir dimensión no la hace semánticamente compatible con bge-m3; requiere entrenamiento, evaluación y una colección/configuración coherente.
- **Entrenamiento por Sequence-Level KD (§3.2)** desde el profesor por login (solo texto): una vía de destilación viable sin logits, no ejecutada en esta versión.
- **Despliegue cuantizado con AWQ INT4 (§4.1)** para caber en 48 GB y correr en el mismo ort de Rust que ya usa el cerebro para BGE-M3.

Qué es reutilizable y qué es solo principio de diseño

Tabla 10. Qué es reutilizable y qué es solo principio de diseño

Mecanismo	Veredicto para el worker
Estado lineal recurrente $d \times d$ (§1.3)	Directamente reutilizable (encoder ONNX)
Selección top-n / gating de NSA (§1.2)	Reutilizable (atender a vectores relacionados)
Sequence-Level KD (§3.2)	Nuestra vía de destilación
AWQ INT4 (§4.1) / GPTQ (§4.2)	Reutilizable (caber y correr)
InfoNCE + last-token + Matryoshka (§4.3–4.5)	Reutilizable (embeddings 1024-dim)
MLA / compresión de KV (§1.1)	Idea sí; export ONNX con fricción
MoE real / routing (§2.1)	Solo el patrón de cabezas; no desplegar
Kernel <i>lightning</i> I/O-aware (§1.3)	Forma recurrente sí; kernel no
Reverse-KL / GKD (§3.3)	Necesitan logits del profesor
KD clásica con temperatura (§3.1)	Necesita logits del profesor

Cuestiones abiertas

- **Sin respaldo primario en este barrido** (fórmulas fundamentales, incluidas por canónicas pero **no re-verificadas** aquí): KD con temperatura T^2 (§3.1), InfoNCE (§4.3), last-token pooling (§4.4), Matryoshka (§4.5). Conviene citarlas como establecidas, no como «verificadas por nosotros».
- forward **vs** reverse **KL** es **debate activo** (§3.4): no cerrar la tesis de MiniLLM como hecho.
- **Fricción real ONNX/Rust** de pesos cuantizados por canal (AWQ INT4) y de MLA/MoE **no está medida** en fuentes primarias: hay que probarlo nosotros.
- **Fidelidad anti-alucinación** de resúmenes *code-to-text* pequeños: no hay evidencia primaria; se medirá con un conjunto etiquetado propio.

Referencias del anexo

Atención y KV: MLA — DeepSeek-V2 2405.04434, DeepSeek-V3 2412.19437 · NSA 2502.11089 · Lightning/lineal — MiniMax-01 2501.08313, MiniMax-M1 2506.13585, Ring-linear 2510.19338 · SSE 2507.16577. **MoE:** DeepSeekMoE 2401.06066 · Loss-Free Balancing 2408.15664. **Destilación:** Hinton 1503.02531 · Sequence-Level KD 1606.07947 · MiniLLM 2306.08543 · GKD 2306.13649 · Forward/Reverse KL 2404.02657. **Cuantización y representación:** AWQ 2306.00978 · GPTQ 2210.17323 · InfoNCE 1807.03748 · e5-mistral 2401.00368 · jina-code-embeddings 2508.21290 · Matryoshka 2205.13147.

Síntesis de la propuesta inicial

Se estudiaron **estado lineal recurrente**, **Sequence-Level KD**, **AWQ** e **InfoNCE + last-token pooling + Matryoshka** como componentes de una red futura. La combinación no fue entrenada ni validada en ONNX/Rust. La versión del producto utiliza generador y embeddings preentrenados separados. MLA, MoE y reverse-KL permanecen como alternativas del estudio con las limitaciones descritas sobre el profesor sin logits.